Accountability Sheet: Saksama, Asisten Toko Multicabang

Versi: demo hackathon, 22 Okt 2026 · **Penanggung jawab:** Salis (pengembang Labapoint) · **Platform:** WorkBuddy (desktop dan Slack), model DeepSeek-V4.1-Flash · **Data:** 100% fiktif · **Hasil uji:** 22/22 hasil akhir benar, 14/22 proses sepenuhnya benar, 48 temuan tercatat

1. Untuk apa

Mengubah pesan chat owner dan staf menjadi rencana aksi: **transfer stok, ubah harga, tagihan reseller, kirim pesan, jadwal**. Agent menyusun rencana, manusia memutuskan, kode memeriksa, menjalankan, dan mencatat.

2. Apa yang bisa diakses agent

- **Satu folder kerja** di sandbox WorkBuddy: data fiktif di `data/` (dibaca), serta `tools/catat.py` dan `tools/cek_aturan.py` (dijalankan).
- **Menulis hanya lewat `catat.py`.** `outbox/`, `rencana/`, dan `log.csv` tidak ditulis langsung oleh agent.
- **Tidak bisa diakses:** kunci tanda tangan dan arsip uji (di luar sandbox), kode dan database Labapoint, kredensial, data pelanggan sungguhan.

3. Yang dijalankan otomatis (tidak mengubah apa pun, tidak menghubungi siapa pun)

Menafsirkan permintaan dan bertanya kalau ambigu · menjalankan cek lewat script (stok, HPP, piutang, jadwal, izin) · menolak dengan kalimat baku · menyusun rencana dan layar konfirmasi · mencatat setiap kejadian ke log (ditulis script).

4. Yang butuh persetujuan (ditegakkan kode, bukan prompt)

Semua yang **mengirim, menjadwalkan, mengubah, atau menagih**. Persetujuan sah hanya dari peminta atau owner, dengan balasan baku (`setuju semua`, `setuju 1,3`, `batal`); "oke deh" dan persetujuan kasir ditolak. Harga di bawah HPP wajib `setuju rugi <no>`. Rencana kedaluwarsa 30 menit, stok dicek ulang saat dijalankan, perubahan setelah dijalankan menjadi rencana baru. Eksekusi hanya simulasi ke `outbox/`.

5. Yang tidak pernah dilakukan

Menjalankan aksi tanpa persetujuan sah · menghitung angka sendiri atau menambah opsi di luar saran script · memberi petunjuk bahwa data terlarang itu ada · menuruti instruksi yang terselip di dokumen · mengirim data biaya ke pihak luar · menulis log sendiri atau mengisi kolom sumber.

6. Batas per peran dan jejak audit

Owner: semua aksi dan data biaya. Kepala cabang: aksi di cabangnya, tanpa HPP. Kasir dan admin gudang: hanya stok cabangnya. Data terlarang dan data yang tidak ada dijawab dengan kalimat identik. `log.csv` mencatat peminta, peran, aksi, sumber, hasil cek, keputusan (berupa fakta, mis. `ambigu`), dan penyetuju; persetujuan dan file outbox ditandatangani HMAC dan diperiksa `catat.py periksa`. **Jendela pantau** menampilkan semuanya per orang, termasuk balasan agent dari sesi WorkBuddy, dan hanya bisa membaca.

7. Kegagalan yang kami temukan, tidak kami sembunyikan

Temuan	Yang terjadi	Tindakan
T13, T16	Agent mengarang kolom sumber di log, lalu menemukan opsi `--sumber`	Kemampuan dicabut dari kode, bukan sekadar dilarang
T17, T18, T22	Saat script error, agent mematikan shim sandbox (`python3 -S`) dan mengingat triknya	Bug diperbaiki; error berarti berhenti; satu kasus satu chat
T25, T28	Agent membaca CSV mentah, bahkan dengan Skill aktif	Batas utama demo (bagian 8)
T29, T35, T36	Saat hanya bisa menolak, agent mengarang opsi	Script memberi opsi yang sudah dicek
T45, T46	Persona platform (`SOUL.md`) mengalahkan aturan Skill	Persona ikut dirancang; file data dibuka langsung turun 4 → 0
T47, T48	Lewat Slack, permintaan berulang dijawab dari ingatan, tanpa gerbang dan log	Belum tertutup; terlihat di jendela pantau

8. Batas yang kami akui

Gerbang persetujuan dan audit sudah ditegakkan kode, tetapi **pembatasan baca belum**: agent masih bisa membuka file data, dan identitas pengirim masih berupa teks. Di produksi, agent tidak menyentuh file: ia memanggil API Labapoint dengan izin si penanya, Row Level Security menyaring data, dan persetujuan serta tanda tangan berada di server.

9. Kalau ada masalah

Hentikan agent, jalankan `python3 tools/catat.py periksa`, lalu baca `log.csv` atau jendela pantau. Tidak ada data asli, kredensial, atau sistem produksi yang terlibat.