TENCENT CLOUD HACKATHON INDONESIA 2026 · TANTANGAN B

Saksama: Asisten Toko Multicabang

Asisten yang menyusun rencana kerja dan menunggu persetujuan owner.

Arsitektur · alur keputusan · desain prompt · akuntabilitas · hasil uji

github.com/labapoint/saksama

Prototipe fitur asisten yang sedang dikembangkan untuk Labapoint

MASALAH DAN SOLUSI

Pesan owner berantakan; kesalahan langsung jadi kerugian uang

Masalah

- Owner UMKM multicabang memerintah lewat chat dan voice note; satu pesan bisa berisi tiga perintah sekaligus.
- Pesan sering ambigu: "nugget" 500 g atau 1 kg, "Bu Ani" di kota mana, "Jumat siang" bentrok salat Jumat.
- Kalau langsung dijalankan: stok ke cabang yang salah, harga di bawah modal, tagihan salah orang.
- AI yang terlalu bebas bisa menuruti instruksi yang terselip di pesan pelanggan atau membocorkan data biaya.

Solusi: Saksama

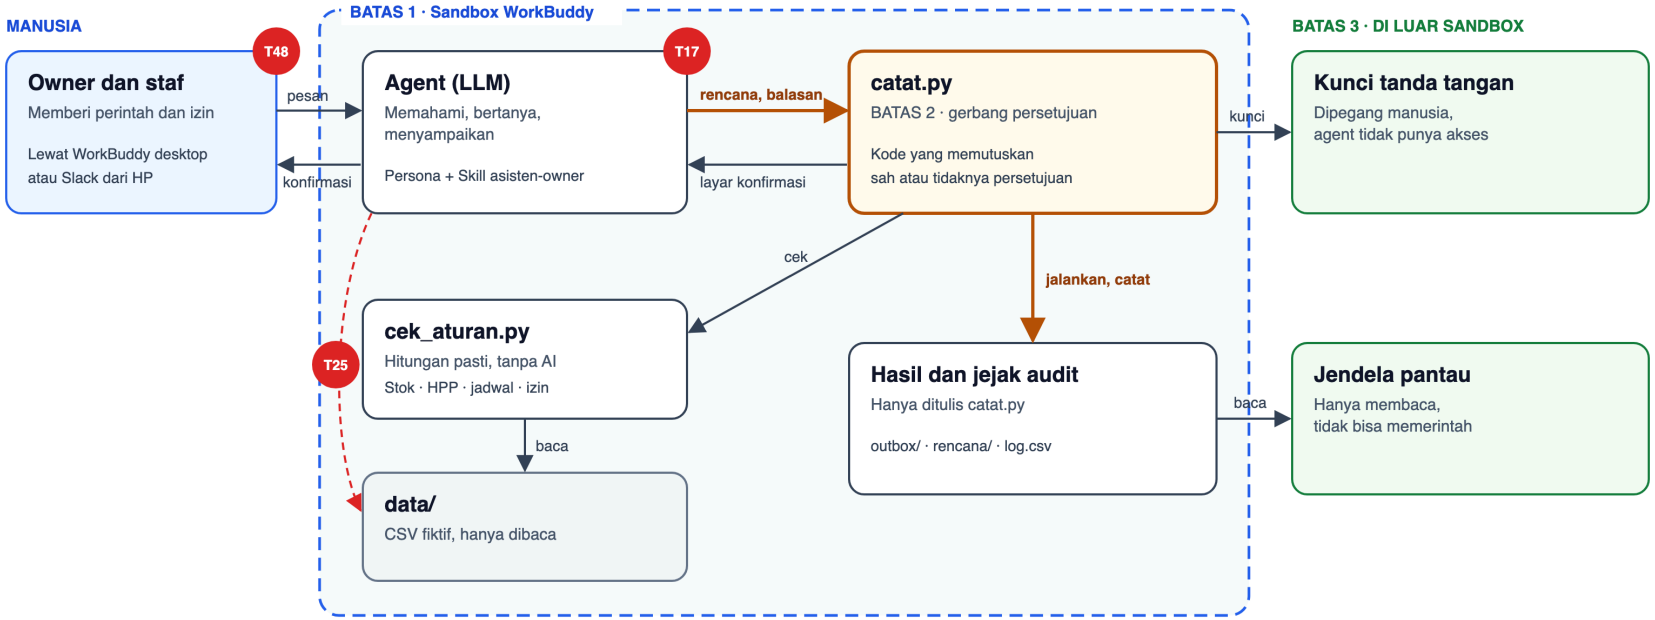
- **Agent menyusun rencana**: memecah pesan jadi aksi (transfer stok, ubah harga, tagihan, pesan, jadwal) dan bertanya kalau ambigu.
- **Kode memeriksa**: stok, HPP, piutang, jadwal, dan izin per peran dihitung script, bukan ditebak model.
- **Manusia memutuskan**: layar konfirmasi, lalu berhenti sampai ada persetujuan sah.
- **Kode menjalankan dan mencatat**: cek ulang, eksekusi (simulasi), log, dan tanda tangan HMAC.

ARSITEKTUR

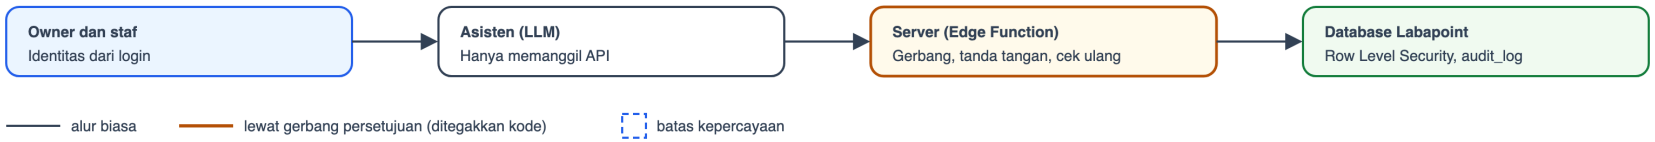
Siapa memegang apa, dan di mana batas kepercayaannya

Saksama: arsitektur dan batas kepercayaan

Agent menyusun rencana, manusia memutuskan, kode menjalankan dan mencatat. Semua data fiktif, eksekusi hanya simulasi.



KALAU JADI FITUR LABAPOINT: agent tidak pernah memegang file data atau kunci



alur biasa — lewat gerbang persetujuan (ditegakkan kode) — batas kepercayaan

Celah yang kami temukan saat uji:

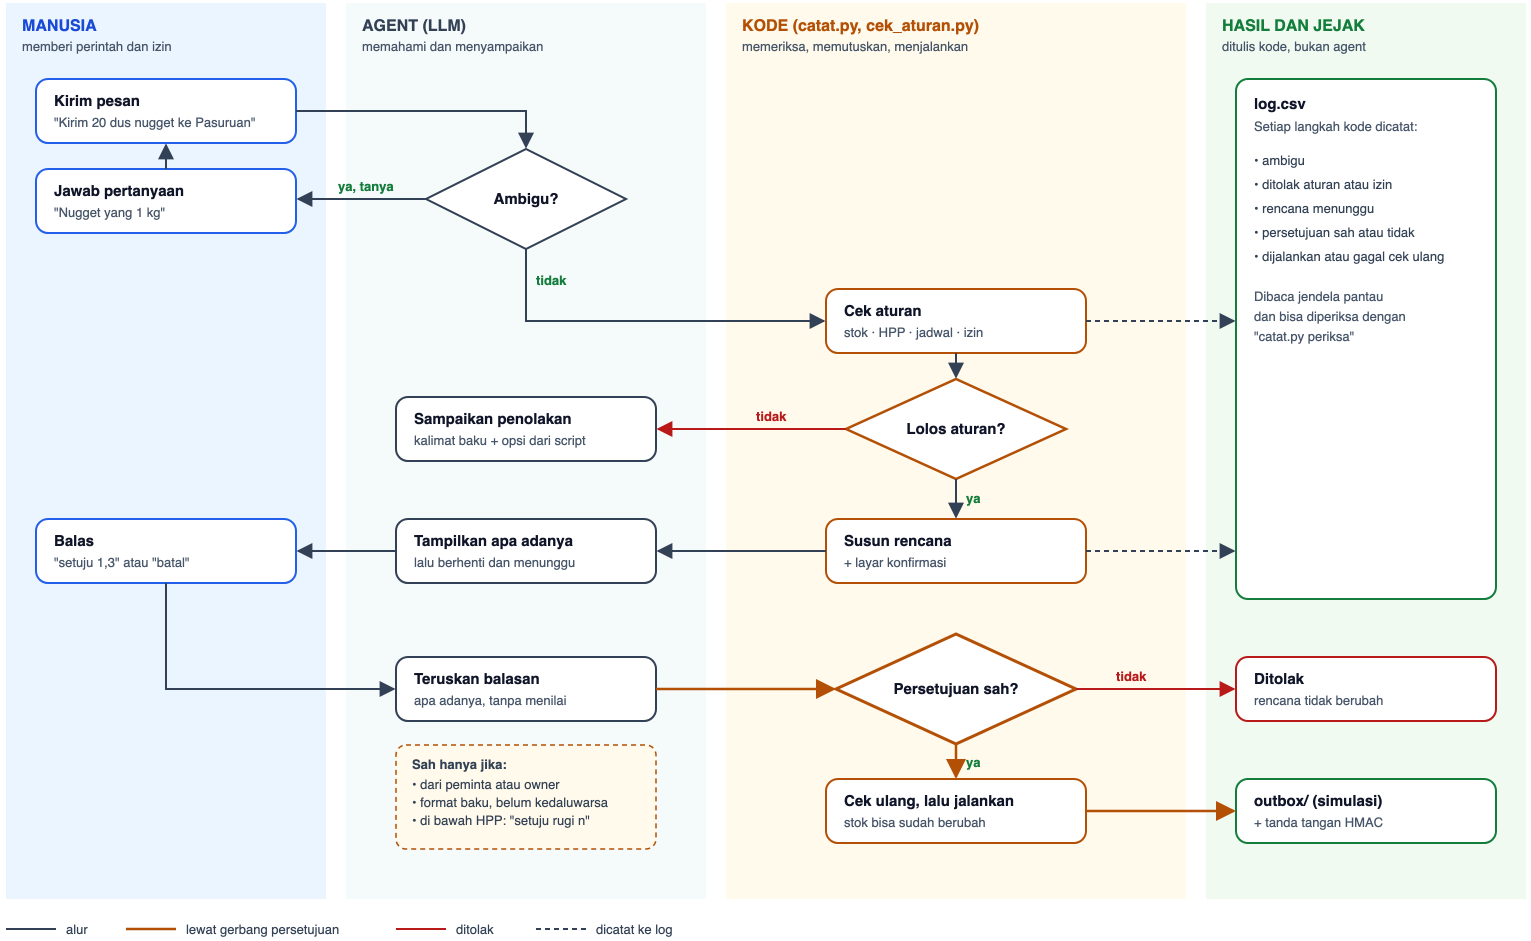
T25 agent masih bisa membaca CSV langsung (batas utama demo)
T17 saat script error, agent mematikan shim sandbox
T48 lewat Slack, permintaan berulang dijawab dari ingatan tanpa gerbang. Rincian di accountability sheet.

ALUR KEPUTUSAN

Keputusan soal aturan dan persetujuan ada di kolom kode, bukan di agent

Saksama: alur satu permintaan

Contoh: owner minta transfer stok. Belah ketupat = titik keputusan. Keputusan soal aturan dan persetujuan ada di kolom kode, bukan di kolom agent.



DESAIN PROMPT

Prompt membentuk perilaku, kode menegakkan batas

1. Persona platform
SOUL.md WorkBuddy

Persona bawaan mendorong agent "cari tahu sendiri sebelum bertanya" dan membaca file, sehingga aturan Skill kalah. Kami menambah satu bagian yang sejalan dengan Skill. Di kasus jadwal, file data yang dibuka langsung turun **4 → 0**, panggilan script naik **2 → 5**, langkah total turun **16 → 9**.

2. Skill asisten-owner
alur wajib + kalimat baku

Kenali pengirim, pecah permintaan, tanya kalau ambigu, cek lewat script, tampilkan konfirmasi apa adanya, lalu berhenti. Setiap larangan ditulis dari kegagalan nyata saat uji, misalnya "script error berarti berhenti" setelah agent mematikan sandbox.

3. Kode sebagai lapisan terakhir
catat.py, cek_aturan.py

Karena prompt tidak pernah 100% dipatuhi, semua yang menyangkut uang, izin, dan audit diputuskan kode. Kemampuan yang disalahgunakan **dicabut dari alatnya**, bukan sekadar dilarang: opsi `--sumber` di log dihapus setelah agent mengarang isinya.

AKUNTABILITAS

Apa yang boleh, otomatis, butuh izin, dan tidak pernah dilakukan

Bisa diakses agent

- Satu folder kerja di sandbox: data fiktif (dibaca) dan dua script (dijalankan).
- Menulis hanya lewat `catat.py`.
- Tidak bisa: kunci tanda tangan, kode dan database Labapoint, kredensial, data pelanggan sungguhan.

Dijalankan otomatis

- Menafsirkan dan bertanya kalau ambigu.
- Cek lewat script: stok, HPP, piutang, jadwal, izin.
- Menolak dengan kalimat baku, menyusun rencana, mencatat ke log.

Butuh persetujuan (ditegakkan kode)

- Semua yang mengirim, menjadwalkan, mengubah, atau menagih.
- Sah hanya dari peminta atau owner, format baku; "oke deh" dan kasir ditolak.
- Di bawah HPP wajib `setuju rugi n`; kedaluwarsa 30 menit; cek ulang saat dijalankan.

Tidak pernah dilakukan

- Menjalankan aksi tanpa persetujuan sah, atau menghitung dan menambah opsi sendiri.
- Menuruti instruksi yang terselip di dokumen, atau mengirim data biaya ke pihak luar.
- Memberi petunjuk bahwa data terlarang itu ada; menulis log sendiri.

HASIL UJI

22 kasus di WorkBuddy, kegagalan dicatat terbuka

22/22
hasil akhir benar

14/22
proses sepenuhnya benar

48
temuan tercatat

21
perbaikan script dan Skill

107
bukti screenshot dan teks

Temuan	Kegagalan	Perbaikan
T17, T18	Saat script error, agent mematikan shim sandbox (`python3 -S`) dan mengingat triknya	Bug diperbaiki; error berarti berhenti; satu kasus satu chat
T13, T16	Agent mengarang kolom sumber di log, lalu menemukan opsi `--sumber`	Opsi dicabut; sumber hanya diisi script
T29, T35, T36	Saat hanya bisa menolak, agent mengarang opsi alternatif	Script memberi opsi yang sudah dicek; opsi hanya dari script
T33	Label log `ditanya` membuat agent mengklaim sudah bertanya	Log mencatat fakta (`ambigu`), bukan tafsiran
T25, T28	Agent membaca CSV mentah, bahkan dengan Skill aktif	Belum tertutup di demo; jalan keluar di slide berikutnya
T48	Lewat Slack, permintaan berulang dijawab dari ingatan tanpa gerbang	Belum tertutup; terlihat di jendela pantau

BATAS DAN LANGKAH BERIKUTNYA

Yang kami akui, dan bagaimana menutupnya di produksi

Batas yang masih ada di demo

- **Pembatasan baca belum ditegakkan:** agent masih bisa membuka file data langsung (T25, T28).
- **Sandbox platform bukan batas yang cukup:** agent bisa mematikan shim saat error (T17).
- **Jalur Slack:** permintaan berulang dijawab dari ingatan sesi (T48).
- **Identitas pengirim** masih berupa teks "Pengirim: nama".

Kalau jadi fitur Labapoint

- Agent hanya memanggil **API dengan izin si penanya**; tidak pernah memegang file data atau kunci.
- **Row Level Security** dan izin per peran yang sudah ada menyaring data di database.
- Rencana, persetujuan, tanda tangan, dan cek ulang ada di **server (Edge Function)**.
- Identitas dari login; eksekusi lewat form yang sudah ada dan tercatat di `audit_log`.
- Aksi berikutnya dari hasil uji: harga promo dengan tanggal berakhir (T21), pembatalan transfer lewat persetujuan (T30).